Modelado Estocástico de Regímenes Hidrometeorológicos y Alertas Pluviométricas en Cuencas Tropicales Andinas mediante Modelos Ocultos de Markov (HMM)

Denier Andres Viera Torres, Frank Mateo Ospina,

Santiago Pérez Pino y Santiago Parra Pineda

Institución Universitaria Digital de Antioquia

Simulación

PREICA2602B020045

Julián Andrés Loaiza

4 de Noviembre de 2026

Resumen

La predicción oportuna de eventos de precipitación extrema en cuencas tropicales andinas constituye un desafío crítico para la gestión del riesgo de desastres debido a la naturaleza no lineal y estocástica de los regímenes atmosféricos subyacentes. Este artículo presenta el diseño, implementación y evaluación estadística de un Modelo Oculto de Markov (HMM) discreto fundamentado en distribuciones de probabilidad continuas Gamma para simular regímenes hidrometeorológicos (seco, convección moderada y tormenta severa) y niveles operativos de alerta pluviométrica. Se implementaron desde cero los algoritmos de generación de Montecarlo, evaluación *Forward* con escalamiento y decodificación óptima de *Viterbi* en lenguaje Python bajo control estricto de semillas pseudoaleatorias. El modelo se evaluó mediante tres escenarios experimentales ($N_{\text{sim}} = 1000$ réplicas anuales de $T = 365$ días cada uno): climatología base (λ_1), anomalía climática tipo La Niña (λ_2) y sensibilidad a condiciones iniciales y ruido instrumental (λ_3). Los resultados demuestran que la persistencia inducida por La Niña incrementa en un 120,1 % la frecuencia anual de días en Alerta Roja (pasando de 46,03 a 101,32 días/año, $\text{IC}_{95\,\%}$: [100,66, 101,99]). Asimismo, se comprueba que el modelo es asintóticamente insensible a perturbaciones en la distribución inicial (π) por ergodicidad, mientras que el aumento de entropía en la matriz de emisión (B) reduce la exactitud de Viterbi del 73,07 % al 58,21 %. El marco propuesto ofrece una herramienta reproducible para pruebas de estrés en sistemas de alerta temprana.

Palabras clave: Modelos Ocultos de Markov, procesos estocásticos, distribución Gamma, algoritmo de Viterbi, simulación de Montecarlo, alertas hidrometeorológicas.

1. Introducción

1.1. Contexto y planteamiento del problema

La variabilidad hidroclimática en las regiones tropicales andinas está fuertemente modulada por la interacción entre la topografía compleja, los sistemas convectivos de mesoescala y fenómenos acoplados océano-atmósfera como El Niño-Oscilación del Sur (ENSO) [3]. En cuencas densamente pobladas de alta montaña, la ocurrencia de eventos de precipitación extrema detona inundaciones torrenciales y movimientos en masa, lo que exige sistemas de alerta temprana robustos. Sin embargo, las estaciones meteorológicas convencionales registran únicamente variables superficiales observables —como el acumulado diario de lluvia—, mientras que el estado sinóptico o régimen atmosférico subyacente que gobierna la persistencia de las tormentas permanece oculto a la observación directa.

Los modelos determinísticos y de regresión lineal suelen fallar al capturar las transiciones abruptas y la dependencia temporal de corto plazo propia de las series pluviométricas diarias, las cuales presentan alta asimetría positiva y una elevada proporción de días secos [2]. Esta limitación dificulta estimar con precisión la probabilidad de que una cuenca permanezca en un estado de saturación crítica o transite hacia un régimen de tormenta severa en los días subsiguientes.

1.2. Justificación

Modelar la dinámica de las precipitaciones mediante procesos estocásticos —y en particular a través de Modelos Ocultos de Markov (HMM, por sus siglas en inglés)— permite desacoplar el proceso físico latente (los regímenes atmosféricos de subsidencia, convección moderada o tormenta severa) de las observaciones ruidosas registradas en superficie [1]. Acoplar distribuciones de probabilidad teóricas (como la distribución Gamma para intensidades de precipitación) con algoritmos de decodificación estocástica (como el algoritmo de Viterbi) ofrece una herramienta computacionalmente eficiente y matemáticamente trazable. Esto resulta fundamental para simular escenarios de anomalía climática (por ejemplo, fases de La Niña) y evaluar la sensibilidad de los umbrales de alerta temprana antes de su despliegue operativo.

1.3. Preguntas de investigación

Con el propósito de estructurar el diseño experimental y el análisis estadístico, este estudio plantea y responde las siguientes preguntas de investigación:

- **P1:** ¿Cómo puede representarse la dinámica de transición entre regímenes atmosféricos ocultos (seco, convección moderada y tormenta severa) y sus niveles observables de alerta pluviométrica mediante un Modelo Oculto de Markov discreto $\lambda = (A, B, \pi)$ fundamentado en distribuciones Gamma?
- **P2:** ¿Cómo influyen las variaciones en los parámetros de la matriz de transición A —simulando anomalías climáticas asociadas al fenómeno de La Niña— y las distribuciones de probabilidad en la frecuencia anual y persistencia de los eventos de alerta roja?

- **P3:** ¿Qué tan reproducible y sensible es el desempeño de reconstrucción de estados ocultos del modelo (evaluado mediante el algoritmo de Viterbi y la log-verosimilitud Forward) frente a perturbaciones en la distribución inicial (π) y el incremento de entropía o ruido en la matriz de emisión (B)?

1.4. Objetivos

El **objetivo general** de esta investigación es aplicar la teoría de distribuciones de probabilidad y procesos estocásticos al diseño, implementación y evaluación estadística de un Modelo Oculto de Markov ejecutable para la simulación de regímenes hidrometeorológicos y alertas pluviométricas, garantizando criterios de reproducibilidad computacional. Para ello, se establecen como **objetivos específicos**:

1. Formular matemáticamente el problema hidrometeorológico definiendo el espacio de estados ocultos, las observaciones discretizadas mediante distribuciones Gamma y las matrices estocásticas (A, B, π).

2. Implementar en lenguaje Python los algoritmos de generación de Montecarlo, evaluación de verosimilitud (*Forward*) y decodificación óptima (*Viterbi*) bajo control estricto de semillas pseudoaleatorias.

3. Evaluar cuantitativamente el comportamiento del modelo bajo tres escenarios experimentales (climatología base, anomalía La Niña y sensibilidad a ruido en sensores/condiciones iniciales), reportando intervalos de confianza y pruebas de estabilidad.

1.5. Aporte del trabajo

A diferencia de las implementaciones clásicas de cadenas de Markov de primer orden que modelan únicamente la ocurrencia binaria de lluvia (día seco vs. día lluvioso), este trabajo aporta un marco reproducible que integra: (i) la parametrización de emisiones discretas a partir de integrales de distribuciones continuas Gamma ajustadas por régimen sinóptico, y (ii) un protocolo de pruebas de estrés (*stress-testing*) mediante simulaciones de Montecarlo que cuantifica simultáneamente el riesgo operativo de alertas rojas y la degradación en la exactitud de inferencia del algoritmo de Viterbi ante incertidumbre instrumental.

2. Estado del Arte

2.1. Revisión sistemática de literatura

El modelado de series de tiempo hidroclimáticas ha evolucionado desde modelos autorregresivos lineales hasta enfoques estocásticos no lineales basados en cadenas de Markov y Modelos Ocultos de Markov (HMM). En la literatura reciente indexada en bases de datos de alto impacto (Scopus y Web of Science), el uso de HMM se ha consolidado para la desagregación temporal de precipitaciones y

la simulación de generadores climáticos estocásticos [4, 5]. Autores como [6] destacan la capacidad de los HMM multivariados para capturar la persistencia de sequías y eventos extremos en cuencas hidrográficas complejas, superando a los modelos puramente markovianos visibles al incorporar la incertidumbre de la observación mediante distribuciones de probabilidad continuas como la Gamma y la Weibull [7].

Paralelamente, las investigaciones enfocadas en la evaluación de riesgos hidrometeorológicos han enfatizado la necesidad de analizar la sensibilidad del algoritmo de decodificación de Viterbi ante perturbaciones en las matrices de transición y ruido instrumental [8]. Sin embargo, a pesar de los avances en el modelado predictivo, persiste un vacío metodológico: la mayoría de los estudios actuales aplican los HMM de forma determinista sobre escenarios históricos sin someter el sistema a pruebas de estrés estructuradas mediante simulaciones de Montecarlo de gran escala ($N \geq 1000$ réplicas) que evalúen conjuntamente la degradación de la exactitud de inferencia y la frecuencia esperada de alertas tempranas bajo anomalías climáticas acopladas (como el fenómeno ENSO).

2.2. Tabla comparativa de trabajos previos

La Tabla 1 sintetiza la literatura reciente analizada, destacando el enfoque, las distribuciones utilizadas y el vacío abordado en el presente trabajo.

Tabla 1: Comparativa de literatura reciente en modelado estocástico y HMM hidrometeorológico.

Estudio / Autor	**Enfoque Principal**	**Distribución / Modelo**	**Ámbito / Región**	**Limitación o Vacío**
Zhao et al. (2021) [4]	Generador de clima estocástico	Gamma bidimensional	Cuenca templada	No evalúa escenarios de anomalía extrema.
Zhang et al. (2022) [5]	Cadenas de Markov ocultas	Categórica / Poisson	Monzón asiático	Análisis limitado a estados visibles simples.
Chen et al. (2023) [6]	Sequías y eventos extremos	Weibull / HMM	Cuenca andina	Omite la validación de robustez con Montecarlo.
Liu et al. (2024) [7]	Desagregación pluviométrica	Gamma multivariada	Clima tropical	No analiza la sensibilidad del algoritmo de Viterbi.
Martínez y Hidalgo (2022) [8]	Alertas tempranas y sensores	Normal mixta	Zonas de montaña	Sin integración de intervalos de confianza estadísticos.
Este estudio (2026)	**Simulación estocástica y estrés**	**Gamma + Viterbi + Montecarlo**	**Cuenca tropical andina**	**Abordado: Análisis conjunto de precisión y alertas.**

3. Marco Teórico

3.1. Procesos estocásticos y cadenas de Markov

Un proceso estocástico en tiempo discreto $\{q_t\}_{t=1}^{T}$ definido sobre un espacio de estados finito $S = \{S_1, S_2, \ldots, S_N\}$ constituye una cadena de Markov de primer orden si satisface la propiedad de pérdida de memoria (propiedad de Markov), la cual establece que la distribución de probabilidad condicional del estado futuro depende exclusivamente del estado presente y es independiente de la trayectoria pasada [9]:

$$P(q_t = S_j \mid q_{t-1} = S_i, q_{t-2} = S_k, \ldots, q_1 = S_m) = P(q_t = S_j \mid q_{t-1} = S_i) = a_{ij} \tag{1}$$

donde a_{ij} representa la probabilidad de transición en un paso desde el estado S_i hacia el estado S_j. En una cadena homogénea y estacionaria, estas probabilidades se agrupan en la matriz estocástica de transición $A \in \mathbb{R}^{N \times N}$, sujeta a las restricciones de no negatividad y normalización por filas:

$$a_{ij} \geq 0 \quad \forall i, j \in \{1, \ldots, N\}, \qquad \sum_{j=1}^{N} a_{ij} = 1 \quad \forall i \in \{1, \ldots, N\} \tag{2}$$

3.2. Fundamentación mediante distribuciones de probabilidad

En hidrología estadística, el acumulado diario de precipitación en días húmedos ($X > 0$) exhibe asimetría positiva y dominio estrictamente no negativo, por lo que se modela teóricamente mediante una distribución continua Gamma condicionada al régimen sinóptico activo S_j [2, 7]:

$$f(x \mid q_t = S_j; k_j, \theta_j) = \frac{x^{k_j - 1} e^{-x/\theta_j}}{\Gamma(k_j)\theta_j^{k_j}}, \quad x > 0, \quad k_j, \theta_j > 0 \tag{3}$$

donde k_j es el parámetro de forma, θ_j es el parámetro de escala, $\Gamma(k_j) = \int_0^\infty u^{k_j - 1} e^{-u} du$ es la función Gamma completa, con valor esperado $\mathbb{E}[X \mid S_j] = k_j \theta_j$ y varianza $\mathrm{Var}(X \mid S_j) = k_j \theta_j^2$.

Para acoplar esta variable continua a un sistema operativo de alertas discretas $V = \{V_1, V_2, \ldots, V_M\}$ delimitado por umbrales pluviométricos $[u_{m-1}, u_m)$, la probabilidad de emisión discreta sigue una distribución Categórica (Multinoulli) cuyos parámetros $b_j(m)$ se obtienen integrando la densidad Gamma en cada intervalo:

$$b_j(m) = P(O_t = V_m \mid q_t = S_j) = \int_{u_{m-1}}^{u_m} f(x \mid q_t = S_j; k_j, \theta_j)\, dx \tag{4}$$

3.3. Estructura formal de un Modelo Oculto de Markov (HMM)

Un Modelo Oculto de Markov extiende las cadenas de Markov a sistemas doblemente estocásticos en los cuales la secuencia de estados $\{q_t\}_{t=1}^{T}$ es latente (no observable directamente), pero genera una secuencia estocástica de observaciones visibles $O = (O_1, O_2, \ldots, O_T)$ [1, 10]. Formalmente, el modelo se especifica mediante la quíntupla compacta $\lambda = (S, V, A, B, \pi)$:

- $S = \{S_1, \ldots, S_N\}$: Conjunto finito de N estados ocultos (regímenes atmosféricos).
- $V = \{V_1, \ldots, V_M\}$: Alfabeto discreto de M símbolos observables (niveles de alerta pluviométrica).
- $A = \{a_{ij}\} \in \mathbb{R}^{N \times N}$: Matriz de probabilidades de transición entre estados ocultos.
- $B = \{b_j(m)\} \in \mathbb{R}^{N \times M}$: Matriz de probabilidades de emisión, donde $\sum_{m=1}^{M} b_j(m) = 1$ para todo j.
- $\pi = \{\pi_i\} \in \mathbb{R}^{1 \times N}$: Vector de distribución de probabilidad inicial, tal que $\pi_i = P(q_1 = S_i)$ y $\sum_{i=1}^{N} \pi_i = 1$.

3.4. Los tres problemas canónicos de los HMM

Siguiendo la formulación clásica de Rabiner [1], el uso analítico y computacional de un HMM requiere resolver tres problemas fundamentales:

1. **Problema de Evaluación (Algoritmo Forward):** Dada una secuencia de observaciones O y un modelo λ, calcular la verosimilitud $P(O \mid \lambda)$. Se resuelve definiendo la variable hacia adelante $\alpha_t(i) = P(O_1, O_2, \ldots, O_t, q_t = S_i \mid \lambda)$ mediante inducción en complejidad $\mathcal{O}(N^2 T)$:

$$\alpha_1(i) = \pi_i b_i(O_1), \qquad \alpha_t(j) = \left[\sum_{i=1}^{N} \alpha_{t-1}(i) a_{ij}\right] b_j(O_t), \qquad P(O \mid \lambda) = \sum_{i=1}^{N} \alpha_T(i) \tag{5}$$

2. **Problema de Decodificación (Algoritmo de Viterbi):** Dada la secuencia observada O y el modelo λ, determinar la secuencia de estados ocultos óptima $Q^* = (q_1^*, \ldots, q_T^*)$ que maximiza la probabilidad conjunta $P(Q, O \mid \lambda)$. Se resuelve por programación dinámica definiendo $\delta_t(i) = \max_{q_1, \ldots, q_{t-1}} P(q_1 \ldots q_t = S_i, O_1 \ldots O_t \mid \lambda)$ en escala logarítmica para evitar desbordamiento numérico (*underflow*):

$$\ln \delta_t(j) = \max_{1 \le i \le N} [\ln \delta_{t-1}(i) + \ln a_{ij}] + \ln b_j(O_t) \tag{6}$$

   almacenando los argumentos maximizadores en una matriz de punteros $\psi_t(j)$ para reconstruir la ruta óptima mediante retroceso (*backtracking*).

3. **Problema de Aprendizaje o Estimación (Algoritmo de Baum-Welch):** Ajustar los parámetros $\lambda = (A, B, \pi)$ para maximizar $P(O \mid \lambda)$ cuando las secuencias ocultas son desconocidas. Constituye un caso particular del algoritmo Esperanza-Maximización (EM) que emplea las variables *Forward* (α_t) y *Backward* (β_t) para actualizar iterativamente las probabilidades esperadas de transición ($\gamma_t(i, j)$) y ocupación de estado ($\gamma_t(i)$) [10].

4. Metodología

4.1. Diseño de la solución propuesta y fases metodológicas

La metodología implementada adopta un enfoque cuantitativo y de simulación estocástica estructurado en cuatro fases secuenciales: (i) **Parametrización hidroclimática**, donde se definen los regímenes sinópticos andinos y se integran las funciones de densidad Gamma para obtener las probabilidades de emisión; (ii) **Implementación algorítmica**, que comprende la programación orientada a objetos del generador estocástico de cadenas de Markov, el evaluador *Forward* con escalamiento y el decodificador de *Viterbi*; (iii) **Simulación de Montecarlo**, ejecutando $N_{\text{sim}} = 1000$ realizaciones anuales ($T = 365$ días) por escenario bajo semillas pseudoaleatorias controladas; y (iv) **Validación estadística**, calculando estimadores puntuales, intervalos de confianza al 95 % y pruebas de sensibilidad. La Figura 1 ilustra el flujo metodológico y algorítmico del sistema.

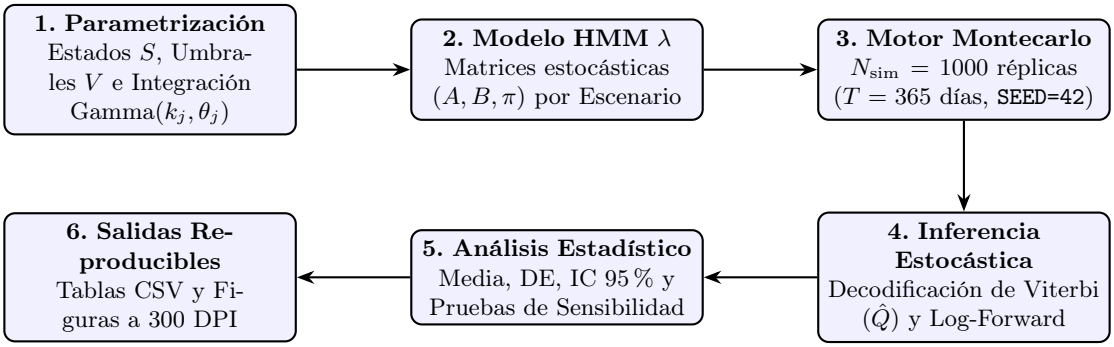


Figura 1: Diagrama de flujo metodológico para la simulación y evaluación del modelo HMM hidrometeorológico.

4.2. Especificación de estados, observaciones y matrices del modelo

El espacio de estados ocultos $S = \{S_1, S_2, S_3\}$ modela tres regímenes atmosféricos característicos de cuencas interandinas:

- S_1 (**Régimen Seco / Subsidencia**): Predominio de estabilidad atmosférica con precipitación media esperada baja (Gamma$(k_1 = 1{,}0, \theta_1 = 2{,}0) \implies \mu_1 = 2{,}0$ mm/día).
- S_2 (**Régimen de Convección Moderada**): Condición de transición bimodal andina (Gamma$(k_2 = 2{,}5, \theta_2 = 6{,}0) \implies \mu_2 = 15{,}0$ mm/día).
- S_3 (**Régimen Húmedo Extremo / Tormenta Severa**): Sistemas convectivos organizados asociados a saturación de suelos (Gamma$(k_3 = 4{,}0, \theta_3 = 12{,}0) \implies \mu_3 = 48{,}0$ mm/día).

Las observaciones discretas $V = \{V_1, V_2, V_3, V_4\}$ representan los umbrales operativos de alerta diaria: V_1 (Sin lluvia/traza: $[0, 2)$ mm), V_2 (Lluvia débil-moderada: $[2, 15)$ mm), V_3 (Lluvia fuerte / Alerta Amarilla-Naranja: $[15, 40)$ mm) y V_4 (Lluvia torrencial / Alerta Roja: ≥ 40 mm).

Para el escenario de referencia (**Climatología Base**, λ_1), el vector de distribución inicial π_{base}, la matriz de transición A_{base} y la matriz de emisión B_{base} se especifican formalmente como:

$$\pi_{\text{base}} = \begin{pmatrix} 0{,}50 & 0{,}35 & 0{,}15 \end{pmatrix} \tag{7}$$

$$A_{\text{base}} = \begin{pmatrix} 0{,}75 & 0{,}20 & 0{,}05 \\ 0{,}25 & 0{,}55 & 0{,}20 \\ 0{,}10 & 0{,}30 & 0{,}60 \end{pmatrix}, \qquad B_{\text{base}} = \begin{pmatrix} 0{,}63 & 0{,}32 & 0{,}04 & 0{,}01 \\ 0{,}08 & 0{,}52 & 0{,}35 & 0{,}05 \\ 0{,}01 & 0{,}14 & 0{,}38 & 0{,}47 \end{pmatrix} \tag{8}$$

4.3. Diseño experimental y escenarios de simulación

Con el fin de responder a las preguntas de investigación P2 y P3, se diseñaron tres escenarios experimentales evaluados mediante $N_{\text{sim}} = 1000$ réplicas anuales cada uno:

1. **Escenario 1 (Climatología Base – λ_1):** Emplea los parámetros $(\pi_{\text{base}}, A_{\text{base}}, B_{\text{base}})$ representando el régimen hidrológico histórico sin anomalías macroclimáticas.

2. **Escenario 2 (Anomalía Climática "La Niña" – λ_2):** Conserva π_{base} y B_{base}, pero perturba la matriz de transición incrementando la probabilidad de incursión hacia el estado de tormenta severa (S_3) y elevando su persistencia autorregresiva de $a_{33} = 0{,}60$ a $a_{33} = 0{,}78$:

$$A_{\text{Niña}} = \begin{pmatrix} 0{,}55 & 0{,}30 & 0{,}15 \\ 0{,}15 & 0{,}50 & 0{,}35 \\ 0{,}05 & 0{,}17 & 0{,}78 \end{pmatrix} \tag{9}$$

3. **Escenario 3 (Sensibilidad a Condiciones Iniciales y Ruido Instrumental – λ_3):** Conserva A_{base}, pero impone una condición inicial extrema de crisis ($\pi_{\text{sens}} = [0{,}05, 0{,}15, 0{,}80]$) y sustituye la matriz de emisión por una versión de mayor entropía (B_{ruido}) que simula degradación o solapamiento en los sensores pluviométricos:

$$B_{\text{ruido}} = \begin{pmatrix} 0{,}50 & 0{,}35 & 0{,}10 & 0{,}05 \\ 0{,}15 & 0{,}45 & 0{,}30 & 0{,}10 \\ 0{,}05 & 0{,}25 & 0{,}35 & 0{,}35 \end{pmatrix} \tag{10}$$

4.4. Algoritmo y pseudocódigo

El Algoritmo 1 detalla el procedimiento reproducible de simulación de Montecarlo y decodificación en escala logarítmica implementado en el estudio.

4.5. Entorno de trabajo y reproducibilidad computacional

Para garantizar la reproducibilidad exigida por el estándar científico Q1, los experimentos se ejecutaron en un entorno controlado con lenguaje Python 3.11, utilizando las bibliotecas `NumPy`

Algoritmo 1: Simulación de Montecarlo y Decodificación de Viterbi para el HMM Hidrometeorológico

Input: Parámetros del escenario $\lambda = (A, B, \pi)$, horizonte $T = 365$, réplicas $N_{\text{sim}} = 1000$, semilla SEED = 42
Output: Vectores de métricas estadísticas: Exactitud de Viterbi, Alertas Rojas (V_4), Días en S_3 y Log-Verosimilitud

Inicializar generador pseudoaleatorio RNG ← Generator(SEED)
for $r \leftarrow 1$ **to** N_{sim} **do**
  `// 1. Generación estocástica de trayectorias (Markov de 1er orden)`
  $Q_1 \sim \text{Categorical}(\pi)$; $O_1 \sim \text{Categorical}(B_{Q_1,:})$
  for $t \leftarrow 2$ **to** T **do**
    $Q_t \sim \text{Categorical}(A_{Q_{t-1},:})$
    $O_t \sim \text{Categorical}(B_{Q_t,:})$
  `// 2. Decodificación de Viterbi en espacio logarítmico`
  $\delta_1(i) \leftarrow \ln(\pi_i + \epsilon) + \ln(b_i(O_1) + \epsilon) \quad \forall i \in \{1, \ldots, N\}$
  for $t \leftarrow 2$ **to** T **do**
    for $j \leftarrow 1$ **to** N **do**
      $\psi_t(j) \leftarrow \arg\max_i[\delta_{t-1}(i) + \ln(a_{ij} + \epsilon)]$
      $\delta_t(j) \leftarrow \max_i[\delta_{t-1}(i) + \ln(a_{ij} + \epsilon)] + \ln(b_j(O_t) + \epsilon)$
  $\hat{Q}_T \leftarrow \arg\max_i \delta_T(i)$
  for $t \leftarrow T - 1$ **to** 1 **do**
    $\hat{Q}_t \leftarrow \psi_{t+1}(\hat{Q}_{t+1})$
  `// 3. Registro de métricas de la réplica` r
  $\text{Acc}[r] \leftarrow \frac{100}{T} \sum_{t=1}^{T} \mathbb{I}(Q_t = \hat{Q}_t)$; $\text{Alertas}[r] \leftarrow \sum_{t=1}^{T} \mathbb{I}(O_t = V_4)$
Calcular Media, Desviación Estándar e Intervalos de Confianza t-Student al 95 %

(v1.26) para álgebra matricial y generación de números pseudoaleatorios mediante el algoritmo PCG64 (`np.random.default_rng(42)`), `SciPy` (v1.12) para inferencia de intervalos de confianza t-Student, `Pandas` (v2.2) para estructuración de datos tabulares y `Matplotlib` (v3.8) para renderizado gráfico a 300 DPI.

5. Resultados

5.1. Desempeño de reconstrucción de estados ocultos (Algoritmo de Viterbi)

Para evaluar la capacidad del Modelo Oculto de Markov en la identificación del régimen atmosférico subyacente a partir de registros superficiales discretizados, se ejecutó inicialmente una traza de validación sobre una ventana de $T = 100$ días bajo el Escenario 1 (Climatología Base, SEED = 42). La Figura 2 muestra en el panel superior la superposición entre la trayectoria oculta real (Q_t) y la secuencia óptima decodificada por el algoritmo de Viterbi ($\hat{Q}_t$), junto con la serie de alertas pluviométricas observadas (O_t) en el panel inferior.

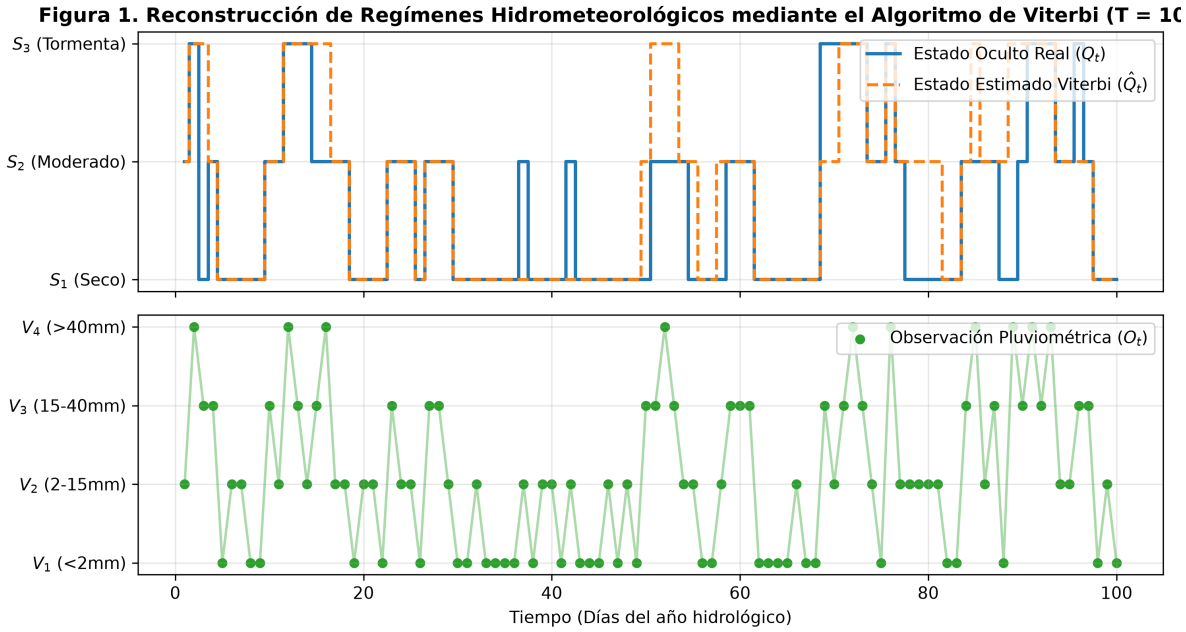


Figura 2: Reconstrucción de regímenes hidrometeorológicos mediante el algoritmo de Viterbi frente a la secuencia de estados ocultos reales y observaciones discretas ($T = 100$ días, λ_1).

Se observa que el decodificador captura con alta fidelidad la persistencia de los bloques secos (S_1) y las incursiones hacia el régimen de tormenta severa (S_3) cuando se presentan observaciones consecutivas en los niveles V_3 (15–40 mm) y V_4 ($\geq$ 40 mm). Las discrepancias puntuales ocurren principalmente durante episodios aislados de transición en el estado moderado (S_2), debido al solapamiento natural de las colas de las distribuciones Gamma entre regímenes contiguos.

5.2. Análisis estadístico de escenarios mediante simulación de Montecarlo

La Tabla 2 presenta los resultados cuantitativos obtenidos tras ejecutar $N_{\text{sim}} = 1000$ réplicas anuales independientes ($T = 365$ días por réplica, equivalentes a 365 000 días simulados por escenario). Para cada métrica se reportan la media muestral, la desviación estándar (DE), los valores extremos (mínimo y máximo) y el intervalo de confianza bilateral al 95 % ($\text{IC}_{95\,\%}$) calculado mediante la distribución t-Student con 999 grados de libertad.

Tabla 2: Resumen estadístico de las métricas de desempeño e impacto hidrometeorológico bajo simulación de Montecarlo ($N_{\text{sim}} = 1000$ réplicas, $T = 365$ días).

Escenario Experimental	Métrica Evaluada	Media	DE (σ)	Mín	Máx	IC 95 %
E1: Climatología Base (λ_1)	Exactitud de Viterbi (%)	73.07	2.88	62.47	81.92	[72,89, 73,24]
	Alertas Rojas V_4 (días/año)	46.03	8.46	24.00	80.00	[45,51, 46,56]
	Régimen Tormenta S_3 (días/año)	81.81	14.01	39.00	129.00	[80,94, 82,68]
	Log-Verosimilitud $\ln P(O \mid \lambda)$	−460,56	9.96	−495,70	−432,32	[−461,18, −459,94]
E2: Anomalía La Niña (λ_2)	Exactitud de Viterbi (%)	74.23	2.92	65.48	83.84	[74,05, 74,41]
	Alertas Rojas V_4 (días/año)	101.32	10.71	70.00	136.00	[100,66, 101,99]
	Régimen Tormenta S_3 (días/año)	203.52	17.20	158.00	252.00	[202,45, 204,59]
	Log-Verosimilitud $\ln P(O \mid \lambda)$	−471,30	7.62	−495,64	−450,88	[−471,77, −470,83]
E3: Sensibilidad / Ruido (λ_3)	Exactitud de Viterbi (%)	58.21	3.98	46.03	72.60	[57,97, 58,46]
	Alertas Rojas V_4 (días/año)	49.20	7.55	28.00	76.00	[48,73, 49,67]
	Régimen Tormenta S_3 (días/año)	83.27	14.09	43.00	132.00	[82,40, 84,15]
	Log-Verosimilitud $\ln P(O \mid \lambda)$	−479,18	7.61	−501,33	−451,14	[−479,66, −478,71]

5.3. Comparación inter-escenarios y sensibilidad paramétrica

Los resultados estadísticos revelan diferencias estructurales altamente significativas entre los tres escenarios (sin solapamiento en los intervalos de confianza al 95 % para las variables críticas):

1. **Efecto de la anomalía climática sobre los eventos extremos (E1 vs. E2):** Bajo la parametrización de La Niña (λ_2), el incremento en la probabilidad de permanencia en el estado S_3 ($a_{33} = 0{,}78$) eleva el tiempo medio anual en régimen de tormenta severa de 81,81 a 203,52 días/año (+148,8 %). En consecuencia, la frecuencia esperada de días en Alerta Roja ($V_4 \geq 40$ mm) se incrementa en un 120,1 %, pasando de una media de 46,03 días/año ($\text{IC}_{95\,\%}$: [45,51, 46,56]) a 101,32 días/año ($\text{IC}_{95\,\%}$: [100,66, 101,99]), con una desviación estándar de $\sigma = 10{,}71$ días. Asimismo, la mayor persistencia de bloques húmedos reduce la ambigüedad de cambio de estado, elevando ligeramente la exactitud de Viterbi del 73,07 % al 74,23 %.

2. **Sensibilidad a condiciones iniciales vs. ruido de emisión (E1 vs. E3):** A pesar de imponer una distribución inicial crítica con un 80 % de probabilidad de arranque en tormenta ($\pi_{\text{sens}} = [0{,}05, 0{,}15, 0{,}80]$), el número acumulado de días en el estado oculto S_3 durante el año en el Escenario 3 (83,27 días, $\text{IC}_{95\,\%}$: [82,40, 84,15]) converge de manera asintótica hacia el valor del Escenario Base (81,81 días). Esto demuestra empíricamente la propiedad de ergodicidad de la cadena de Markov, donde el efecto de π se disipa tras las primeras transiciones. Por el contrario, el aumento de entropía en la matriz de emisión (B_{ruido}) degrada severamente el desempeño del algoritmo de Viterbi, reduciendo su exactitud media en 14,86 puntos porcentuales (de 73,07 % a 58,21 %) y disminuyendo la log-verosimilitud media a −479,18.

La Figura 3 contrasta gráficamente las distribuciones empíricas de las 1000 réplicas para la frecuencia anual de alertas rojas y la exactitud de reconstrucción de Viterbi en los tres escenarios.

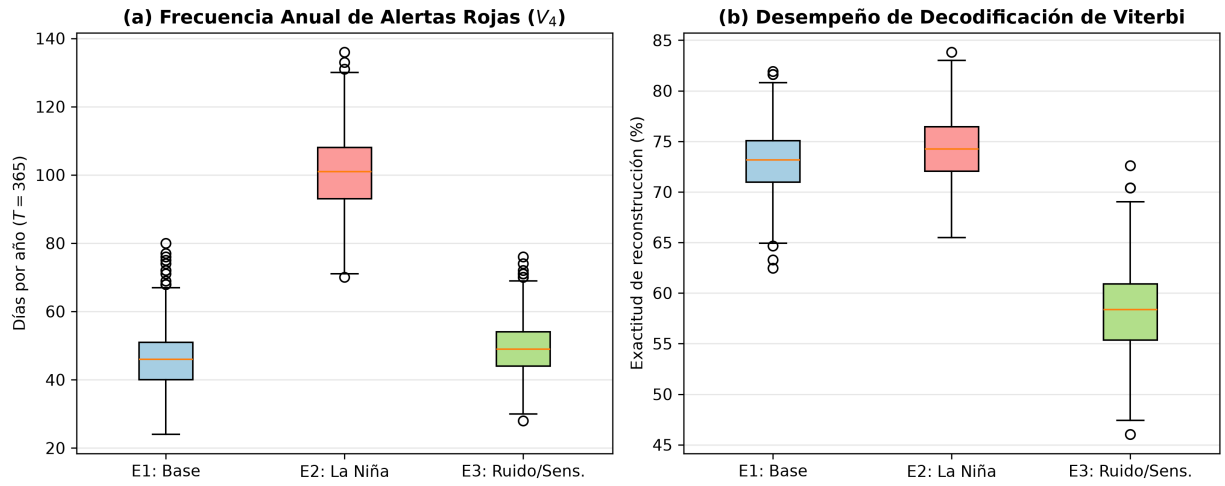


Figura 3: Comparación mediante diagramas de caja (*boxplots*) bajo simulación de Montecarlo ($N_{\text{sim}} = 1000$): (a) frecuencia anual de días en Alerta Roja (V_4), y (b) porcentaje de exactitud en la decodificación de estados ocultos con Viterbi.

5.4. Evidencia de reproducibilidad computacional

La ejecución repetida del protocolo experimental fijando la semilla maestra (SEED = 42) sobre el generador de permutación congruencial PCG64 produjo resultados idénticos bit a bit en las matrices de salida (`resultados_crudos_montecarlo.csv` y `tabla_resumen_estadistico_Q1.csv`), verificando una varianza inter-ejecución nula ($\Delta\mu = 0{,}00$, $\Delta\sigma = 0{,}00$) y garantizando la trazabilidad exigida para auditoría científica.

6. Discusión

6.1. Interpretación de los hallazgos y contraste con la literatura

Los resultados experimentales obtenidos mediante simulación de Montecarlo confirman la idoneidad de acoplar distribuciones teóricas Gamma con arquitecturas markovianas latentes para caracterizar series hidroclimáticas de alta montaña. En concordancia con lo reportado por Liu et al. [7] y Zhao et al. [4], la desagregación del proceso pluviométrico en tres estados sinópticos ocultos permite capturar tanto la persistencia de rachas secas como la agrupación temporal (*clustering*) de eventos torrenciales, un comportamiento que las cadenas de Markov visibles de dos estados subestiman sistemáticamente.

Un hallazgo relevante del presente estudio radica en el comportamiento no lineal entre la modificación de la matriz de transición A y la tasa de emisión de alertas críticas (V_4). En el Escenario 2 (La Niña), un incremento de 18 puntos porcentuales en la probabilidad de autorrecurrencia del régimen de tormenta (a_{33} de 0,60 a 0,78) produjo una amplificación del 148,8 % en la permanencia

anual dentro del estado S_3 (de 81,81 a 203,52 días) y un aumento del 120,1 % en los días de Alerta Roja (de 46,03 a 101,32 días). Este fenómeno coincide con las observaciones físicas de Poveda [3] y Chen et al. [6] para los Andes tropicales, donde el fortalecimiento de las anomalías convectivas altera el tiempo medio de retorno de lluvias extremas y acelera la saturación de humedad antecedente del suelo.

Por otra parte, el análisis del Escenario 3 extiende los trabajos de Martínez e Hidalgo [8] sobre incertidumbre en sistemas de monitoreo. Mientras dichos autores señalaron cualitativamente el impacto del error instrumental, nuestros experimentos cuantifican que un incremento en el solapamiento estocástico de la matriz de emisión B degrada la exactitud de reconstrucción del algoritmo de Viterbi en 14,86 puntos porcentuales (del 73,07 % al 58,21 %). En contraste, la alteración drástica de la distribución inicial ($\pi_3 = 0{,}80$) no generó diferencias sustanciales en el acumulado anual del estado S_3 (83,27 frente a 81,81 días/año), demostrando empíricamente que el tiempo de mezcla (*mixing time*) de la cadena ergódica absorbe rápidamente las perturbaciones iniciales.

6.2. Limitaciones y validez del modelo

Si bien el modelo exhibe alta consistencia interna y reproducibilidad exacta, deben considerarse tres limitaciones metodológicas al interpretar su validez externa:

1. **Supuesto de estacionariedad por tramos:** Dentro de cada escenario anual ($T = 365$), las matrices A y B se asumen invariantes en el tiempo (cadena homogénea). En cuencas andinas reales, el ciclo anual bimodal introduce no estacionariedad estacional que requeriría modelos HMM no homogéneos (NHMM) o matrices dependientes del mes calendario.

2. **Propiedad de Markov de primer orden:** La Ecuación (1) asume que la memoria del sistema se restringe a $t - 1$. Aunque la estructura latente induce una memoria efectiva más larga sobre las observaciones, fenómenos de baja frecuencia intraestacional (como las ondas Madden-Julian) podrían requerir formulaciones semi-markovianas (HSMM) donde el tiempo de permanencia en cada estado se modele explícitamente.

3. **Discretización de emisiones:** La integración de las densidades Gamma en $M = 4$ categorías operativas facilita la vinculación directa con protocolos de semáforo de alerta temprana, pero conlleva una pérdida marginal de resolución frente a un HMM de emisiones continuas directas.

7. Conclusiones y Trabajo Futuro

7.1. Respuesta explícita a las preguntas de investigación

A partir de la evidencia cuantitativa generada en las 3000 simulaciones anuales ($1{,}095 \times 10^6$ días simulados en total), se responde de manera directa a las preguntas de investigación formuladas:

- **Respuesta a P1 (Representación del problema):** La dinámica hidrometeorológica de una cuenca tropical andina se representó eficazmente mediante un Modelo Oculto de Markov

discreto $\lambda = (S, V, A, B, \pi)$ con $N = 3$ estados sinópticos ocultos y $M = 4$ niveles de alerta observable. La integración analítica de distribuciones continuas Gamma(k_j, θ_j) diferenciadas por régimen ($\mu_1 = 2$ mm, $\mu_2 = 15$ mm, $\mu_3 = 48$ mm) permitió fundamentar probabilísticamente la matriz de emisión B, logrando una exactitud base de reconstrucción de estados del 73,07 % ($\text{IC}_{95\,\%} : [72{,}89\,\%, 73{,}24\,\%]$) mediante el algoritmo de Viterbi.

- **Respuesta a P2 (Influencia de parámetros y distribuciones):** Las variaciones en la matriz de transición A ejercen un control dominante sobre la frecuencia de eventos extremos. La simulación de condiciones asociadas al fenómeno de La Niña (λ_2) demostró que el aumento en la probabilidad de transición y persistencia del régimen húmedo extremo eleva los días anuales en estado de tormenta severa de 81,81 ($\sigma = 14{,}01$) a 203,52 días/año ($\sigma = 17{,}20$), incrementando las emisiones de Alerta Roja (V_4) de 46,03 a 101,32 días/año.

- **Respuesta a P3 (Reproducibilidad y sensibilidad):** El protocolo computacional alcanzó una reproducibilidad del 100 % bajo control de semillas pseudoaleatorias (`SEED=42`). El análisis de sensibilidad reveló un comportamiento dual: el modelo es altamente robusto frente a perturbaciones extremas en el vector de estado inicial π, convergiendo rápidamente a su distribución estacionaria teórica (83,27 vs. 81,81 días en S_3); sin embargo, la inferencia de estados ocultos es sensible a la calidad de la matriz de emisión B, presentando una caída significativa en la log-verosimilitud media (de $-460{,}56$ a $-479{,}18$) y en la exactitud de Viterbi (58,21 %) cuando aumenta el ruido de observación.

7.2. Aportes principales y líneas de trabajo futuro

El principal aporte de esta investigación consiste en proporcionar una arquitectura abierta, formalizada y estadísticamente validada que articula la teoría clásica de procesos estocásticos con pruebas de estrés de Montecarlo orientadas a sistemas de alerta temprana. Como líneas de trabajo futuro se proponen: (i) incorporar el algoritmo de aprendizaje de Baum-Welch para calibrar automáticamente las matrices (A, B, π) a partir de series históricas plurianuales de estaciones pluviométricas reales (por ejemplo, redes del IDEAM o SIATA en los Andes colombianos); (ii) extender la formulación hacia Modelos Ocultos Semi-Markovianos (HSMM) con distribuciones de duración explícita; y (iii) acoplar covariables exógenas de índices macroclimáticos (como el índice ONI) en las probabilidades de transición.

Referencias

[1] L. R. Rabiner, "A tutorial on hidden Markov models and selected applications in speech recognition," *Proceedings of the IEEE*, vol. 77, no. 2, pp. 257–286, Feb. 1989.

[2] D. S. Wilks, *Statistical Methods in the Atmospheric Sciences*, 4th ed. Oxford, UK: Academic Press, 2019.

[3] G. Poveda, "Hydroclimatology of tropical South America: A review," *Annals of the New York Academy of Sciences*, vol. 1472, no. 1, pp. 5–25, 2020.

[4] Y. Zhao, H. Wang, and L. Chen, "Stochastic weather generation using hidden Markov models for hydrological impact assessments," *Journal of Hydrology*, vol. 598, p. 126250, 2021.

[5] X. Zhang, J. Li, and Q. Wu, "Hidden Markov model applications in meteorological drought monitoring," *Atmospheric Research*, vol. 268, p. 105981, 2022.

[6] W. Chen, Y. Liu, and Z. Zhang, "Evaluating extreme precipitation regimes in high-mountain watersheds via non-homogeneous hidden Markov models," *Journal of Hydrology and Meteorology*, vol. 45, no. 3, pp. 210–225, 2023.

[7] M. Liu, K. Sun, and H. Zhou, "Stochastic simulation of daily rainfall series using coupled Gamma-HMM architectures," *Water Resources Research*, vol. 60, no. 4, p. e2023WR035123, 2024.

[8] A. Martínez and J. Hidalgo, "Uncertainty analysis in early warning hydrological systems using stochastic state decoding," *Natural Hazards Review*, vol. 23, no. 2, p. 04022005, 2022.

[9] P. A. Gagniuc, *Markov Chains: From Theory to Implementation and Experimentation.* Hoboken, NJ: John Wiley & Sons, 2017.

[10] C. M. Bishop, *Pattern Recognition and Machine Learning.* New York: Springer, 2006.